Décomposition itérative de x-vecteurs par Rotated Matching Pursuit Sparse Autoencoder (RMP-SAE)

1 Contexte et Objectifs

Les **x-vecteurs** sont des plongements (embeddings) profonds très performants pour la reconnaissance du locuteur. Cependant, leur espace latent d-dimensionnel est fortement intriqué : un même axe mélange des informations relatives au timbre, au sexe, à la prosodie ou au canal d'enregistrement.

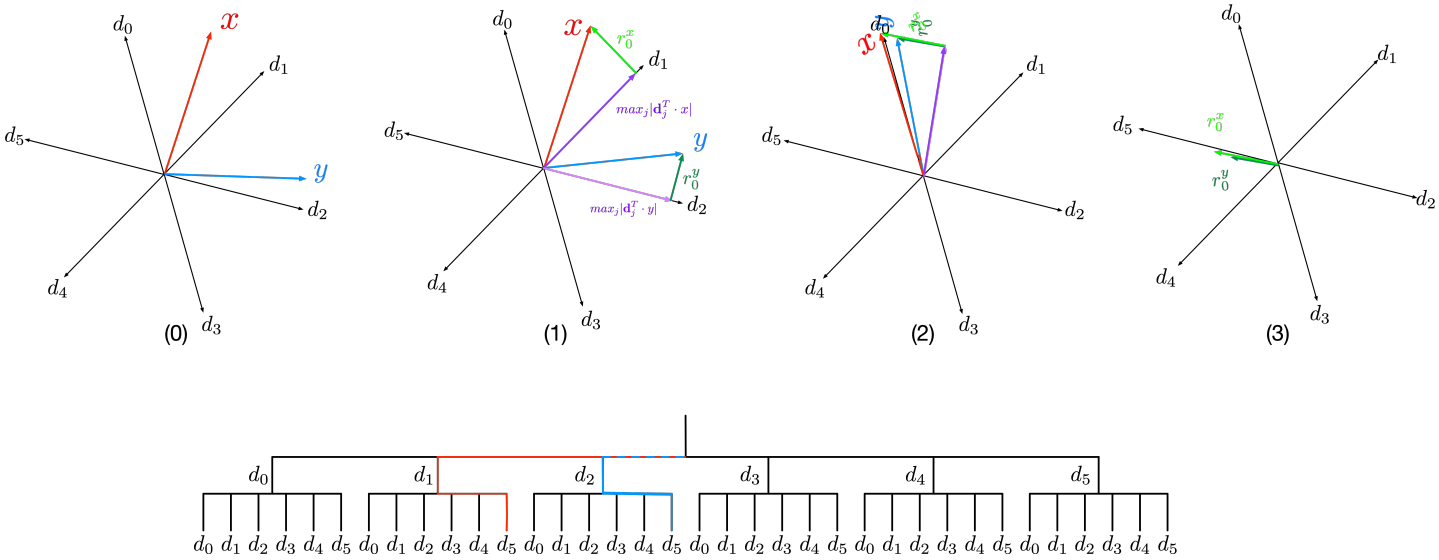


FIGURE 1 : Fonctionnement d'un RMP-SAE, des x-vecteurs, x et y sont projetés sur une base sur-complète $\{d_0, d_1, d_2, d_3, d_4, d_5$ (Figure 0). Le prototype maximisant cette projection est sélectionné (d_1 pour x et d_2 pour y) (Figure 1) et la projection sur celui-ci, <$d_1 \cdot x$>, est soustraite du x-vecteur originel pour obtenir un résidu (r_0^x et r_0^y). Les résidus sont rotationnés afin d'être replacés dans un espace canonique commun. Le processus est ré-itéré k fois pour obtenir une décomposition de chaque x-vecteur qui peut être représentée par l'arbre ci-dessus.

Objectif du projet

L'objectif est d'implémenter un **Rotated Matching Pursuit Sparse Autoencoder (RMP-SAE)**. Contrairement aux auto-encodeurs classiques qui projettent l'entrée en une seule passe, le RMP-SAE décompose le x-vecteur de manière itérative :

1. À chaque étape k, une **transformation de rotation** $\mathbf{R}_k \in SO(d)$ est appliquée au résidu de reconstruction pour réaligner sa variance maximale dans un espace canonique commun.
2. L'atome du dictionnaire sur-complet le plus corrélé au résidu réaligné est sélectionné.
3. Sa contribution est ré-inversée et soustraite du résidu pour l'étape suivante.

Ce processus de recadrage dynamique garantit que le dictionnaire travaille sur des résidus homogènes et permet d'extraire des « concepts monosémantiques » strictement décorrélés et fortement interprétables.

2 Modélisation Mathématique

Soit un x-vecteur initial $\mathbf{x} \in \mathbb{R}^d$ et un dictionnaire sur-complet fixe de D atomes $\mathbf{D}_{\text{dic}} \in \mathbb{R}^{d \times D}$ ($D \gg d$), dont chaque colonne $\mathbf{d}_j$ est de norme unitaire ($\|\mathbf{d}_j\|_2 = 1$).

1. Algorithme d'encodage itératif avec résidu rotaté

On initialise le résidu dans l'espace original $\mathbf{r}_0 = \mathbf{x}$ et la représentation parsemée $\mathbf{z} = \mathbf{0} \in \mathbb{R}^D$. Pour chaque étape $k = 1, \ldots, K$:

1. **Rotation et alignement du résidu :** On applique une matrice de rotation $\mathbf{R}_k \in SO(d)$ (apprise via un module dédié ou calculée par alignement de covariance) pour projeter le résidu dans l'espace de référence cano-

nique :

$$\tilde{\mathbf{r}}_{k-1} = \mathbf{R}_k \mathbf{r}_{k-1} \tag{1}$$

2. **Sélection de l'atome dans l'espace aligné :** On identifie l'atome du dictionnaire ayant la plus forte projection absolue avec le résidu réaligné :

$$j_k = \arg \max_{j \in \{1,\dots,D\}} \left| \mathbf{d}_j^T \tilde{\mathbf{r}}_{k-1} \right| \tag{2}$$

3. **Calcul du coefficient d'activation :**

$$c_k = \mathbf{d}_{j_k}^T \tilde{\mathbf{r}}_{k-1} \tag{3}$$

4. **Mise à jour du résidu et du code latent :** Le résidu dans l'espace original est mis à jour en ré-inversant la rotation ($\mathbf{R}_k^{-1} = \mathbf{R}_k^T$ car $\mathbf{R}_k$ est orthogonale) :

$$\mathbf{r}_k = \mathbf{r}_{k-1} - c_k \mathbf{R}_k^T \mathbf{d}_{j_k} \tag{4}$$

$$z_{j_k} = z_{j_k} + c_k \tag{5}$$

La reconstruction finale dans l'espace d'origine après K étapes s'écrit :

$$\hat{\mathbf{x}} = \sum_{k=1}^{K} c_k \mathbf{R}_k^T \mathbf{d}_{j_k} \tag{6}$$

2. Régularisation d'Orthogonalité et Perte globale

Pour préserver la propriété Isométrie Presque Parfaite ($SO(d)$) et garantir que les transformations $\mathbf{R}_k$ soient de vraies rotations sans déformation d'échelle, on impose la pénalité d'orthogonalité :

$$\mathcal{L}_{\text{orth}} = \sum_{k=1}^{K} \left\| \mathbf{R}_k^T \mathbf{R}_k - \mathbf{I}_d \right\|_F^2 \tag{7}$$

La fonction de perte globale optimisée sur le dictionnaire $\mathbf{D}_{\text{dic}}$ et les modules de rotation $\mathbf{R}_k$ s'écrit :

$$\mathcal{L} = \frac{1}{2} \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 + \lambda_{\text{orth}} \mathcal{L}_{\text{orth}} \quad \text{s.t.} \quad \|\mathbf{d}_j\|_2 = 1, \ \forall j \in \{1, \dots, D\} \tag{8}$$

3 Travail à réaliser (Jalons du projet)

Data Pipeline & Baseline OMP sans rotation

Charger les fichiers `.npy`. Normaliser l'espace original des x-vecteurs. Implémenter une baseline standard avec *Orthogonal Matching Pursuit* (OMP) sans rotation du résidu pour pouvoir mesurer quantitativement le gain apporté par l'alignement dynamique.

Implémentation PyTorch du RMP-SAE

Développer l'architecture modulaire en PyTorch :

- Concevoir le module de rotation $\mathbf{R}_k$: tester deux approches (1. paramétrisation explicite via exponentielle matricielle / formule de Cayley, ou 2. calcul analytique d'alignement SVD/PCA sur le batch de résidus).
- Implémenter la boucle itérative de Matching Pursuit avec réalignement $\tilde{\mathbf{r}}_{k-1} = \mathbf{R}_k \mathbf{r}_{k-1}$ et projection inverse $\mathbf{R}_k^T \mathbf{d}_{j_k}$.
- Coder la renormalisation sur la sphère unité des colonnes du dictionnaire $\mathbf{D}_{\text{dic}}$.

Entraînement & Convergence

Entraîner le modèle avec l'optimiseur AdamW :

- Étudier la décroissance de la norme du résidu $\|\mathbf{r}_K\|_2$ selon le nombre d'étapes $K \in \{5, 10, 20, 50\}$.

— Vérifier si l'alignement du résidu permet de réduire le phénomène d'atomes morts dans le dictionnaire ($D = 2d$ à $8d$) comparé au MP classique.

Vérifiez la cohérence des représentations obtenues, on souhaite que pour un même locuteur, les représentations des différents vecteurs appartenant à ce locuteur partagent les mêmes prototypes pour les premières étapes de décomposition.

Évaluation de l'Interprétabilité et Désintrication (6h)
Analyser la sémantique des composantes extraites au fil des étapes k :

Probing linéaire : Entraîner des classifieurs légers à partir des codes **z** pour prédire l'identité du locuteur et les métadonnées.

Démonstrateur & Visualisation (4h)
Développer une interface interactive (Streamlit / Gradio) affichant :

— La trajectoire du résidu $\mathbf{r}_k$ projetée en 2D/3D (via UMAP) avant et après application de la rotation $\mathbf{R}_k$.

— La courbe de décroissance de l'erreur de reconstruction étape par étape.

4 Ressources et Références

— Mallat, S. G., & Zhang, Z. (1993). *Matching pursuits with time-frequency dictionaries*. IEEE Transactions on Signal Processing.

— Engan, K., et al. (1999). *Method of optimal directions for frame design*. IEEE ICASSP.